SAMSUNG SW AI ACADEMY FOR YOUTH

對外秘

# 프로젝트 명세서

AI 기반 도서 분석과 창작 지원 통합 솔루션 서비스

(Python)

“데이터 크롤링 프로젝트”

5 회차

對外秘

목차

1. 데이터 크롤링 프로젝트 ..... 3

1.1 목표 ..... 3

1.2 준비사항 ..... 3

1.3 작업 순서 ..... 4

1.4 요구사항 ..... 5

1.5 참고자료 ..... 13

1.6 프로젝트 결과 ..... 13

# 1. 데이터 크롤링 프로젝트

## 1.1 목표

본 프로젝트의 목표는 Django 기반 웹 애플리케이션에서 Selenium을 활용한 실시간 데이터 크롤링과 LLM 기반 데이터 증강 파이프라인을 구현하는 것이다.

- Django 웹 애플리케이션 구조를 이해하고 활용할 수 있다.
- 사용자 입력을 기반으로 서버 측에서 크롤링 로직을 실행할 수 있다.
- Selenium을 활용하여 동적 웹 페이지(토스증권)에서 데이터를 수집할 수 있다.
- 수집된 데이터를 전처리하고, LLM(GMS)을 활용해 텍스트 데이터를 증강할 수 있다.
- 원본 데이터와 가공·증강 데이터를 웹 화면에 통합 출력할 수 있다.

## 1.2 준비사항

1) 프로젝트 구조

- 본 프로젝트는 Django 기반 웹 애플리케이션으로 구성된다.
  - 전체 시스템은 기능별 역할이 명확히 구분된 구조를 가지며, 입력 처리, 데이터 수집, 데이터 가공, 결과 출력의 흐름으로 동작한다.
  - 사용자로부터 입력된 정보는 서버에서 처리되며, 외부 서비스로부터 필요한 데이터를 수집하는 과정을 포함한다.
  - 수집된 데이터는 단계별 가공 과정을 거쳐 결과로 생성되며, 각 처리 단계는 독립적으로 관리되어 재사용이 가능하도록 구성한다.
  - 데이터 처리 과정은 요청 시점에 실행되며, 별도의 사전 데이터 저장 없이 실시간으로 수행된다.
  - 처리된 결과는 사용자가 확인할 수 있도록 웹 화면에 출력되며, 요청에 따라 동적으로 변경된다.
  - 전체 시스템은 입력 -> 처리 -> 출력의 일관된 구조를 기반으로 동작한다.

2) 사용 데이터

- 토스증권 커뮤니티 댓글 데이터
  - 사용자 입력 회사명 기반 검색
  - 검색 결과 최상단 회사 기준
  - 커뮤니티 탭의 댓글 텍스트
- 데이터는 사전에 저장되지 않으며,
  - 요청 시 실시간 크롤링
  - 결과는 화면에 출력
- 증강 데이터는 GMS LLM API를 통해 생성된다.

3) 개발언어 및 툴

- Python
- Django
- Selenium WebDriver
- Visual Studio Code
- 웹 브라우저 (Chrome 권장)

4) 필수 라이브러리 / 오픈소스

- django
  - 웹 애플리케이션 프레임워크
- selenium
  - 동적 웹 페이지 크롤링
- webdriver-manager
  - ChromeDriver 자동 관리
- re
  - 정규 표현식을 활용한 텍스트 전처리
- GMS LLM API
  - SSAFY 내부 제공 생성형 AI API
  - 텍스트 데이터 증강에 활용데이터 바인딩 및 컴포넌트 기반 UI 구성을 위한 프레임워크

## 1.3 작업 순서

1) 팀원과 같이 요구사항(기본/심화)을 확인한다.

2) 직접 토스 증권에 접속하여 회사 검색 및 댓글 목록 위치를 확인한다.

3) 개발 사항 및 수정(개선) 등 할 일을 정하고 역할을 분담한다.

4) 요구사항에 맞는 기능을 구현하고 테스트한다.

5) 팀원과 함께 추가적인 아이디어를 논의하고 정리한다.

6) 추가 아이디어를 적용하여 프로젝트를 완성한다.

7) 산출물을 정리하여 GitLab 에 반영한다.

## 1.4 요구사항

본 프로젝트는 Django 서버에서 실행되는 크롤링·데이터 가공 파이프라인 구현을 목표로 한다. 사용자 입력 -> 크롤링 -> 전처리 -> 데이터 증강 -> 결과 출력의 흐름을 하나의 웹 서비스로 완성한다.

Django의 프로젝트 명과 어플리케이션 명은 자유롭게 설정하여 개발을 진행한다.

■ **요구사항 예시 (참고용)**

- 아래의 내용을 참고하여 추가적인 아이디어에 대해 요구사항을 추가 또는 수정하여 기능을 구현한다. 단, 필수 기능은 반드시 구현해야 하며 수정할 수 없다.

| 기능적 요구사항 | | | | |
|---|---|---|---|---|
| **번호** | **분류** | **요구사항명** | **요구사항 상세** | **우선순위** |
| F601 | 입력 | 회사명 입력 및 검증 | 사용자는 웹 화면을 통해 회사명을 입력할 수 있어야 하며, 입력값이 없는 경우 데이터 수집 절차가 수행되지 않도록 제한한다. 회사명은 일부 문자열 입력이 가능해야 한다. | 필수 |
| F602 | 데이터 저장 | DB 스키마 구성 | 각 단계의 결과를 저장할 수 있도록 스키마를 구성하고 마이그레이션 과정을 수행한다. | |
| F603 | 데이터 조회 | 회사 검색 및 선택 | 입력된 회사명을 기준으로 외부 증권 서비스에서 회사 검색을 수행하며, 검색 결과가 여러 개인 경우 최상단에 노출된 회사를 자동으로 선택한다. | 필수 |
| F604 | 데이터 수집 | 커뮤니티 댓글 데이터 수집 | 선택된 회사의 상세 페이지로 이동한 후 커뮤니티 영역에 접근하여 댓글 텍스트 데이터를 수집한다. | 필수 |
| F605 | 데이터 전처리 | 댓글 데이터 정제 | 수집된 댓글 데이터에 대해 길이 기준 필터링, 특수문자 제거, 불필요한 공백 제거 등 기본적인 전처리 작업을 수행한다. | 필수 |
| F606 | 데이터 증강 | 텍스트 데이터 증강 | 전처리된 댓글 데이터를 기반으로 생성형 언어 모델을 활용하여 의미를 | 필수 |

| | | | | |
|---|---|---|---|---|
| | | | 유지한 확장 텍스트 데이터를 생성한다. | |
| F607 | 데이터 통합 | 데이터 통합 관리 | 원본 댓글 데이터, 전처리 데이터, 증강 데이터를 하나의 결과 집합으로 통합하여 관리하고 출력한다. | 필수 |
| F610 | 데이터 분석 | 댓글 요약 생성 | 수집된 전체 댓글 데이터를 기반으로 주요 내용을 요약한 결과를 생성하여 함께 출력한다. | 심화 |
| F611 | 시스템 처리 | 예외 상황 처리 및 안내 | 회사 검색 결과가 없거나 댓글 데이터가 존재하지 않는 경우, 사용자에게 상태를 안내하는 메시지를 출력한다. | 심화 |
| … | … | … | … | … |

## 1. 기본 기능 (필수)

사용자로부터 회사 이름을 입력받고, 토스증권에서 해당 회사의 댓글 데이터를 수집하는 기능을 구현한다. 전체 디자인은 자유롭게 구성한다.

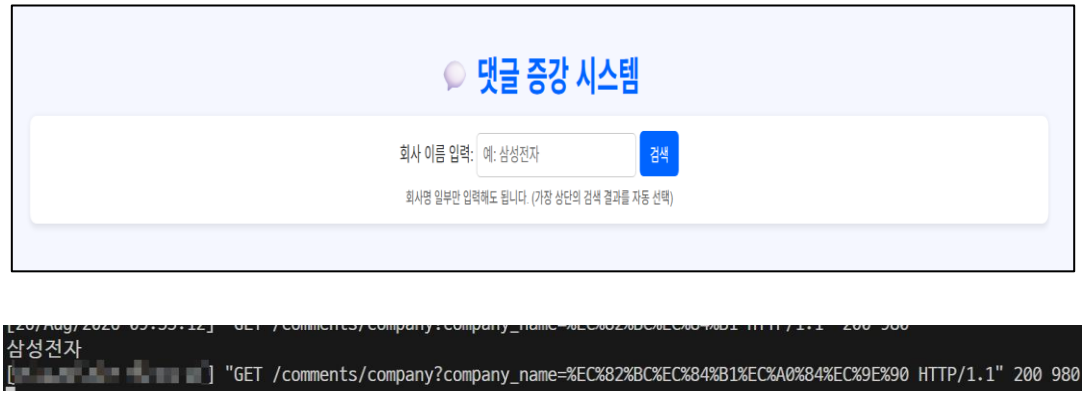
### 1) Django 를 활용하여 회사명 입력 및 검증 기능을 구현한다.

① 요구사항 번호 : F601

② 사용자로부터 회사명을 입력받는 입력 창을 작성한다.

③ 입력값이 있는 경우 VS Code 터미널에 입력한 회사명이 출력되도록 한다.

④ 입력값이 없는 경우 아무런 동작을 수행하지 않도록 한다.




<그림 1> 사용자 입력 기능 결과 예시

2) **각 단계의 결과를 저장할 수 있도록 구성한다.**

① 요구사항 번호 : F602

② 데이터 수집, 전처리, 증강 각 단계의 결과를 데이터베이스에 모두 저장할 수 있도록 설계한다.

③ 저장해야 할 데이터는 다음과 같다.

- 실제종목명: 실제 매칭된 종목의 공식 명칭
- 원본 댓글 목록
- 정제 댓글 목록
- 증강 댓글 목록
- IQR 임계값 정보
- 생성 일시

④ 실제 DB가 생성될 수 있도록 마이그레이션을 완료한다.

3) **회사 검색 및 대상 회사를 선택한다.**

⑤ 요구사항 번호 : F603

⑥ 입력된 회사명을 기준으로 외부 증권 서비스에서 회사를 검색한다.

- 토스 증권 홈페이지의 검색 과정은 아래 이미지를 참고한다.

⑦ 검색 결과 중 최상단에 노출된 회사를 자동으로 선택한다.

- 예시) “삼성” 검색 시 “삼성전자” 자동 검색

- 존재하지 않는 회사에 대한 처리는 요구사항 F601 에서 구현

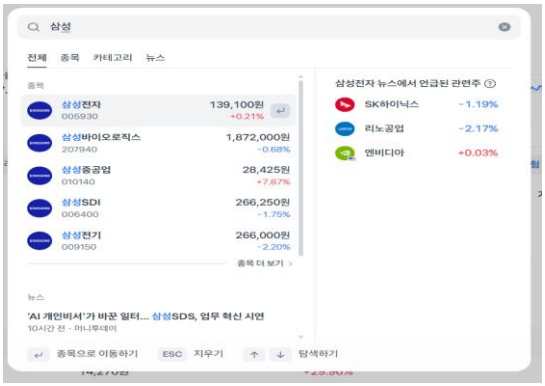
⑧ [선택] 스트리밍 기능을 활용하여 크롤링 진행 상황을 적절히 출력한다.




**<그림 2> 크롤링 진행 상황 출력 예시**




**<그림 3> 토스증권 홈페이지 - 우측 상단 검색창 클릭**




**<그림 4> 토스증권 홈페이지 - 모달창 화면 (최상단 회사 자동 포커싱)**

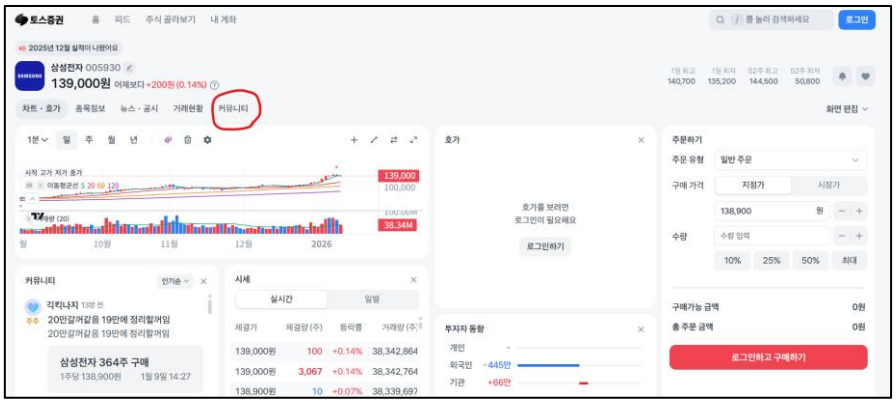
4) **커뮤니티 댓글 데이터를 수집한다.**

① 요구사항 번호 : F604

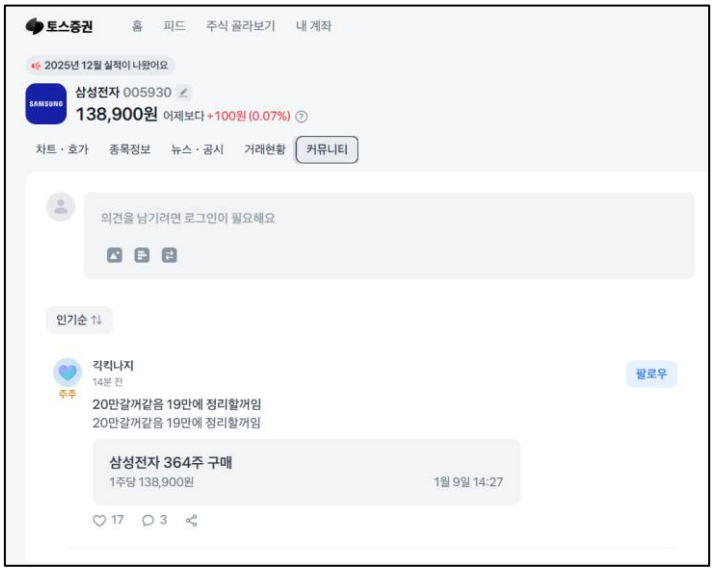
② 선택된 회사의 상세 페이지에 접근하여 커뮤니티 영역으로 이동한다.

③ 커뮤니티 영역에 게시된 댓글 텍스트 데이터를 수집한다.

- 20 개의 데이터를 수집하도록 구성한다.




**<그림 5> 토스증권 홈페이지 - 커뮤니티 탭 위치**




**<그림 6> 토스증권 홈페이지 - 댓글 목록 위치**

5) **댓글 데이터에 대한 전처리를 수행한다.**

① 요구사항 번호 : F605

② 댓글 데이터에 대한 전처리를 수행한다.

- 필수 전처리

◆ 결측치 혹은 길이가 너무 짧거나 긴 댓글 제거
(길이 5 이상 ~ 76 이하)

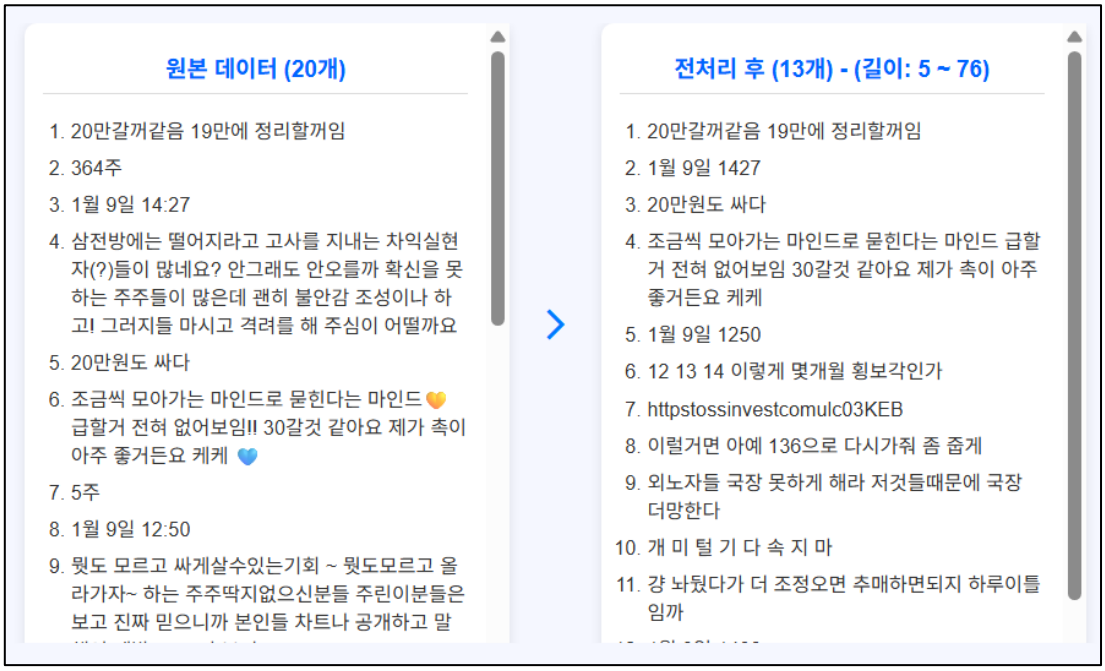
◆ 특수문자(의미없는 댓글) 와 불필요한 패턴 제거(ㅋㅋㅋ 등)

◆ 부적절한 댓글 데이터 제거(LLM API 호출을 통하여 구현)

✓ 프롬프트 예시: 다음 댓글 목록에서 부적절한 댓글(욕설, 혐오, 비방, 선정성, 과도한 비난 등)의 번호(0 부터 시작)만 JSON 배열로 알려줘

- 이후 데이터 증강 및 통합 단계에서 활용 가능하도록 구성한다.

③ 결과를 화면에서 확인할 수 있도록 UI 를 자유롭게 구성한다.
(아래 이미지는 단순 참고)




**<그림 7> 원본 데이터 및 전처리 후 데이터 출력 결과 예시**

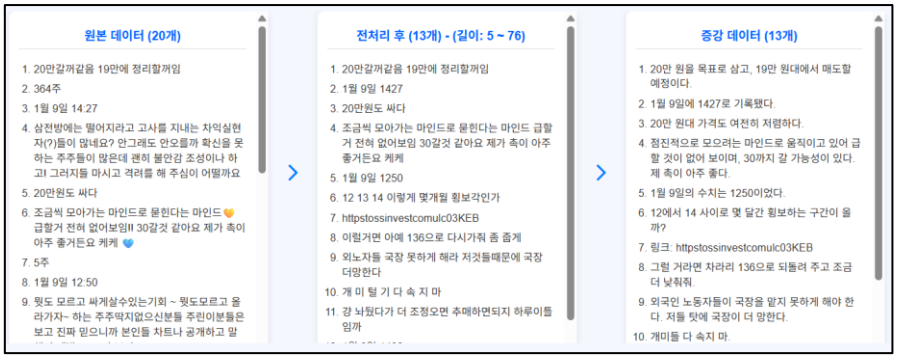
6) **텍스트 데이터 증강을 수행한다.**

① 요구사항 번호 : F606

② 전처리된 댓글 데이터를 기반으로 텍스트 데이터를 증강한다.

③ 기존 댓글의 의미를 유지한 상태로 확장된 데이터를 생성한다.

④ 결과를 화면에서 확인할 수 있도록 UI 를 자유롭게 구성한다.
(아래 이미지는 단순 참고)




**<그림 8> 증강 데이터 출력 결과 예시**

7) **통합된 데이터 결과를 출력한다.**

① 요구사항 번호 : F607

② 원본 데이터, 전처리 데이터, 증강 데이터를 하나의 결과 집합으로 통합 및 DB 에 저장한다.

③ 단계별 데이터 구분이 가능하도록 관리한다. (아래 이미지는 단순 참고)




**<그림 9> 통합 데이터 출력 결과 예시**

## 2. 심화 기능 (선택)

심화 기능은 수집된 댓글 데이터를 요약하여 의미 있는 정보를 도출하고, 데이터 미존재 등 예외 상황에 대한 안내를 제공함으로써 실제 서비스 환경을 고려한 데이터 수집·처리 흐름을 확장 구현하는 것을 목표로 한다.

### 8) 댓글 데이터를 요약하여 제공한다.

① 요구사항 번호 : F610

② 수집된 전체 댓글 데이터를 기반으로 주요 내용을 요약한다.

③ 요약 결과를 기존 데이터와 함께 출력한다.

- 출력 화면은 자유롭게 선택한다.
- 예시 1) 화면 하단 텍스트로 출력
- 예시 2) 요약 버튼 클릭 시 화면에 출력 (바이브 코딩으로 구현)

### 9) 예외 상황에 대한 안내를 제공한다.

① 요구사항 번호 : F611

② 회사 검색 결과 또는 댓글 데이터가 존재하지 않는 경우를 처리한다.

③ 사용자에게 현재 상태를 안내하는 메시지를 출력한다.

## 1.5 참고자료

- Django 공식 문서
  **https://docs.djangoproject.com/**
- Selenium 공식 문서
  **https://www.selenium.dev/documentation/**
- MDN Web Docs - 정규 표현식(Regular Expression)
  **https://developer.mozilla.org/ko/docs/Web/JavaScript/Guide/Regular_expressions**

## 1.6 프로젝트 결과

아래 내용들을 모두 포함하여 GitLab 에 업로드한다.

프로젝트 이름은 프로젝트 번호 + -pjt 로 지정한다. (ex) 05-pjt)

### ■ 산출물과 제출

1) 구현 소스 코드

◆ 프로젝트 전체 소스 코드를 제출한다.

2) 실행 결과 캡처본

◆ 각 요구사항에 대한 실행 결과 화면을 캡처한다.

3) README.md

◆ 주요 기능 설명, 학습 내용, 느낀 점을 반드시 포함한다.

- 以上